



Data mining con Chat-GPT

Andrea Sciarrillo

Master Data Science - UniCusano

- 
1. Intro
 2. Data Analysis
 3. Data Viz
 4. Machine Learning
 5. Chat GPT
 6. Conclusioni



Introduzione

Obiettivi

- condurre un'analisi da *data scientist*
 - analisi esplorativa dei dati
 - provare algoritmi di Machine Learning
- verificare funzioni di Chat GPT

Tools: Python (in Google Colab) e fogli di calcolo

Dataset: Adult Census Income, fonte Kaggle

famoso e di pubblico dominio, sono informazioni del Census Bureau Database (ente pubblico USA) con dati socio-economici sui cittadini

Data Analysis

Preparazione dell'ambiente

→ caricamento dataset e librerie (es. pandas, sklearn, graphvizz)

Analisi dati

→ focus sulle variabili, le loro peculiarità e correlazioni.

Con l'ausilio di statistica descrittiva e i raggruppamenti tra categorie, poi con visualizzazione grafica e formulando ipotesi.

Informazioni generali sul dataset

visione tabellare con funzione data.head

recap colonne e tipologia valori contenuti con funzione data.info →

statistica descrittiva sulle variabili numeriche con data.describe

```
adult_test.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16281 entries, 0 to 16280
Data columns (total 15 columns):
#   Column              Non-Null Count  Dtype  
---  -
0    age                 16281 non-null  int64  
1    workclass           16281 non-null  object  
2    fnlwgt              16281 non-null  int64  
3    education           16281 non-null  object  
4    education-num       16281 non-null  int64  
5    marital-status      16281 non-null  object  
6    occupation          16281 non-null  object  
7    relationship        16281 non-null  object  
8    race                16281 non-null  object  
9    sex                 16281 non-null  object  
10   capital-gain         16281 non-null  int64  
11   capital-loss         16281 non-null  int64  
12   hours-per-week       16281 non-null  int64  
13   native-country      16281 non-null  object  
14   income              16281 non-null  object  
dtypes: int64(6), object(9)
memory usage: 1.9+ MB
```

Data Analysis 2

```
adult_test[["age", "education-num", "capital-gain", "capital-loss", "hours-per-week"]].describe()
```

	age	education-num	capital-gain	capital-loss	hours-per-week
count	16281.000000	16281.000000	16281.000000	16281.000000	16281.000000
mean	38.767459	10.072907	1081.905104	87.899269	40.392236
std	13.849187	2.567545	7583.935968	403.105286	12.479332
min	17.000000	1.000000	0.000000	0.000000	1.000000
25%	28.000000	9.000000	0.000000	0.000000	40.000000
50%	37.000000	10.000000	0.000000	0.000000	40.000000
75%	48.000000	12.000000	0.000000	0.000000	45.000000
max	90.000000	16.000000	99999.000000	3770.000000	99.000000

Numero righe dati di test: 16281
Numero colonne dati di test: 15

	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	income
0	25	Private	226802	11th	7	Never-married	Machine-op-inspct	Own-child	Black	Male	0	0	40	United-States	<=50K
1	38	Private	89814	HS-grad	9	Married-civ-spouse	Farming-fishing	Husband	White	Male	0	0	50	United-States	<=50K
2	28	Local-gov	336951	Assoc-acdm	12	Married-civ-spouse	Protective-serv	Husband	White	Male	0	0	40	United-States	>50K
3	44	Private	160323	Some-college	10	Married-civ-spouse	Machine-op-inspct	Husband	Black	Male	7688	0	40	United-States	>50K
4	18	?	103497	Some-college	10	Never-married	?	Own-child	White	Female	0	0	30	United-States	<=50K



Data Analysis 3


Alcuni insights

- le categorie di reddito, ovvero la **variabile target**, sono solamente due:
le persone che guadagnano **meno di 50k annuali** o **quelle con più di 50k/anno**
→ la maggior parte dei soggetti non supera la soglia dei 50k/anno
- **sexo predominante** → **maschile** (rappresenta circa due terzi della popolazione totale)
- l'**età media** generale è di **38.7 anni**, con le donne mediamente più giovani.
- l'età media del **gruppo <50k** si attesta a **36.7 anni** ed è inferiore di quasi 8 punti rispetto all'altro: probabilmente il **reddito si alza in quella fascia di età (45+)**
visto che la **carriera professionale** dovrebbe aver raggiunto quasi il suo picco.
- si trova conferma di un trend presente anche tuttora:
il sesso femminile è usualmente associato a minori guadagni

Data Visualization


Maggiore istruzione, maggiore reddito: correlazione

Scatter plot



incide anche il fattore della categoria di lavoro svolto (ad esempio ruoli dirigenziali) o della propensione ad accumulare denaro a seguito di investimenti (capital gain), il quale alza il reddito totale dell'individuo.

Data Visualization 2



Si può affermare che tendenzialmente più il grado di istruzione è alto, più alta è la propensione ad investire capitale e più è probabile essere nel gruppo +50k di reddito

Quasi tutti coloro che acquisiscono capitale da investimenti finanziari si collocano nel gruppo positivo dei +50k

Data Visualization 3

Lavoro

Settore più diffuso: privato


Lavori più remunerativi:

- Imprenditoria
- Enti federali
- Executive Manager

Relazioni


Il matrimonio conviene!

Unica categoria con una rilevante predisposizione ad avere reddito alto è quella degli sposi civili (circa 6 su 14).



Data Visualization 4

Relazioni tra le variabili





Machine Learning

Preparazione dell'ambiente

- caricamento librerie ML
- codifica variabili
- split dati di test e dati di training

Processo sui modelli

- esecuzione codice apprendimento
- predizione etichetta
- test di accuratezza
- matrice di confusione
- report di classificazione

```
# converto sesso in dato numerico
n_sex = {"Male": 0, "Female": 1}
train['sex'] = train['sex'].map(n_sex)
test['sex'] = test['sex'].map(n_sex)

# converto razza in dato numerico
n_race = {"Amer-Indian-Eskimo": 1, "Asian-Pac-Islander": 2, "Black": 3, "Other": 4, "White": 5}
train['race'] = train['race'].map(n_race)
test['race'] = test['race'].map(n_race)

# converto workclass in dato numerico
n_workclass = {"?": 0, "Federal-gov": 1, "Local-gov": 2, "Never-worked": 3, "Private": 4, "Self-emp-inc": 5}
train['workclass'] = train['workclass'].map(n_workclass)
test['workclass'] = test['workclass'].map(n_workclass)

# converto marital-status in dato numerico
n_marital = {"Divorced": 1, "Married-AF-spouse": 2, "Married-civ-spouse": 3, "Married-spouse-absent": 4, "Never-married": 5, "Widowed": 6}
train['marital-status'] = train['marital-status'].map(n_marital)
test['marital-status'] = test['marital-status'].map(n_marital)
```

OBIETTIVO: PREDIRE LA FASCIA DI REDDITO DEGLI INDIVIDUI

apprendimento supervisionato



Machine Learning 2

Modello 1: Support Vector Machine, testato su tutto il dataset analizzato.

Modello 2: Decisione Tree, testato su tutto il dataset analizzato.

Modello 3: Light Tree (Decision Tree)

Qui ho applicato tutte le ipotesi formulate nella fase di analisi esplorativa, riducendo quindi la quantità di informazioni in pasto al modello.

Modello 4: Skinny Tree (Decision Tree)

Alle precedenti, ho integrato le osservazioni emerse dalla tabella di correlazione.

Marital-status e relationship sono due voci simili: ho ritenuto opportuno usare solo la più correlata statisticamente al reddito, ovvero la seconda, riducendola a variabile binaria: sposato o non sposato. Esclusi poi sesso, categorie del lavoro ed età, quest'ultima già in parte coperta da livello di istruzione e dalla variabile matrimoniale.

Modello 5: Decision Tree by Chat-GPT

Chat GPT

Di cosa si tratta?

AN

Come lo spiegheresti ad un bambino?



Ciao! Chat GPT è un computer molto intelligente che può capire quello che scrivi e risponderti come se stessi parlando con una persona vera. È stato addestrato a capire come funziona la nostra lingua e ad imparare molte cose interessanti che può condividere con te! È un po' come avere un amico robot con cui puoi parlare quando vuoi.

AN

e ad un anziano?



Chat GPT è un assistente virtuale, ovvero un programma di computer che è stato addestrato per interagire con le persone in modo simile a come lo farebbe un essere umano. Puoi pensarlo come un assistente digitale che ti aiuta a rispondere alle tue domande e risolvere i tuoi problemi, proprio come lo farebbe una persona reale. Utilizza l'intelligenza artificiale per capire ciò che gli viene chiesto e fornire risposte appropriate. Puoi utilizzare Chat GPT per ottenere informazioni, aiuto con problemi tecnici, consigli su argomenti vari e molto altro ancora.



Chat GPT 2

Gli ho chiesto di creare un modello per predire la variabile target del nostro dataset.

Ecco cosa ha fatto:

- ❑ Caricamento del dataset
- ❑ Codifica della variabile target
- ❑ Codifica delle variabili categoriche
- ❑ Separazione dei dati di addestramento e test
- ❑ Addestramento del modello
- ❑ Valutazione del modello
- ❑ Stampa della matrice di confusione e del report di classificazione

Da notare che il modello proposto ha addestrato meno dati e solo le seguenti variabili:
'workclass', 'education', 'marital.status', 'occupation', 'relationship', 'race', 'sex', 'native.country'

Conclusioni

Obiettivi raggiunti! Lavoro da data scientist e test di coding su GPT



Per quanto riguarda le prestazioni dei modelli:

Modello	Tempo esecuzione	Accuracy	<=50k (0) Precision	<=50k (0) Recall	>50k (1) Precision	>50k (1) Recall
SVM	>45 minuti	0,80	0,81	0,95	0,65	0,30
DT	0"	0,81	0,88	0,87	0,61	0,60
"Light" DT	0"	0,83	0,87	0,91	0,66	0,57
"Skinny" DT	0"	0,85	0,87	0,91	0,77	0,53
GPT DT	0"	0,81	0,88	0,87	0,60	0,62

- Accuracy (accuratezza): rapporto tra le previsioni corrette sul totale delle previsioni
- Precision: proporzione di identificatori positivi effettivamente corretta sul totale dei positivi
- Recall (richiamo): rapporto tra veri positivi e la somma di veri positivi e falsi negativi



Conclusioni 2

Il primo obiettivo della tesi, quello di condurre una vera e propria analisi da Data Scientist, è stato soddisfatto. Difatti l'analisi dei dati è stata utile e completa e ha permesso di migliorare gli algoritmi di machine learning secondo ipotesi data-driven. Più precisamente, da una parte l'analisi dei dati si addice maggiormente ad una figura di Data Analyst, mentre l'inserimento di tecniche matematiche per la previsione di eventi sono proprie di un Data Scientist

L'ultimo step è dunque stato la verifica delle capacità di Chat GPT in ambito di coding e programmazione: in questo caso il programma ha innanzitutto dimostrato una importante velocità a fornire output interessanti, oltre a potere recuperare interi dataset in autonomia e sviluppare codice in base alle richieste dell'utente. Tuttavia, l'intervento umano appare ancora necessario viste alcune lacune sulla codifica delle variabili e le prestazioni dei modelli proposti, questi ultimi che appaiono di basilare concezione e probabilmente migliorabili se lavorati da specialisti matematici ed esperti di machine learning. Si noti che nonostante ciò, il chatbot, per sua stessa ammissione, è strumento che predilige l'elaborazione di linguaggio naturale, quindi la creazione di testi e contenuti e quindi più utile ad altre figure già viste nel master, quali influencer, content creator, editor, webmaster, social media manager.



Conclusioni 3

Spunti di miglioramento:

- Fondamentale capire a fondo i motivi delle prestazioni così basse sul gruppo positivo (nonostante fosse la minor parte della popolazione), anche sulla base delle motivazioni date dal chatbot (disuguaglianza classi, mancanza caratteristiche discriminanti, overfitting) e provare soluzioni da lui proposte
- In un'ottica di upskilling professionale è di primaria importanza ottimizzare il codice e razionalizzare le sequenze di creazione delle variabili e dei sub-set, affinché il codice possa risultare meno confusionario e così accorciare un progetto per renderlo più godibile e comprensibile nelle rivisitazioni
- Un ottimo modello da provare ad utilizzare su questo dataset, anche vedendo la grande diffusione nelle community di esperti e appassionati, è il Random Forest
- Per quanto riguarda le applicazioni di AI, sarebbe opportuno un confronto con altri competitor di Chat GPT sull'attuale mercato nel settore (escludendo i software alimentati dallo stesso).