

Abbandoni: early predicting

Obiettivo del progetto

- Sviluppare un modello di **early predicting** per identificare in anticipo gli studenti a rischio di abbandono.
- L'idea è intervenire tempestivamente con azioni mirate di supporto, basandosi esclusivamente su informazioni note **al momento dell'immatricolazione**.



UNIVERSITÀ
DI PAVIA

Servizio Qualità
e gestione della domanda

Dati utilizzati

- Studenti immatricolati nel **triennio 2021–2023**.
- Variabili considerate:
 - 📍 **Provenienza geografica** (residenza, distanza dalla sede, capoluogo vs provincia).
 - 🏫 **Percorso scolastico** (tipo di diploma, voto, lode).
 - 👤 **Caratteristiche anagrafiche** (età, sesso, cittadinanza).
 - 🎓 **Scelta universitaria** (corso di studio, dipartimento, accesso libero/numero chiuso).
 - 🤝 **Partecipazione a eventi COR** (orientamento)

Approccio

- Analisi e preparazione dei dati.
- Costruzione di modelli predittivi.
- Valutazione comparata delle performance, con focus su recall (intercettare più abbandoni possibili) e interpretabilità.

Lavoro di preparazione dei dati (Preprocessing)

Prima di poter costruire e addestrare modelli predittivi, è stato necessario svolgere un importante lavoro di preparazione dei dati. I dati amministrativi contengono infatti molte informazioni utili ma:

- non tutte sono rilevanti per il problema dell'abbandono;
- alcune sono ridondanti o rumorose;
- altre sono registrate in formati non adatti direttamente all'uso in un modello matematico.

Il preprocessing è servito quindi a ripulire, trasformare e arricchire i dati affinché fossero coerenti, compatti e significativi per la predizione.



Le fasi principali del lavoro

01

Pulizia e selezione delle variabili

- Sono state eliminate colonne ridondanti o inutili per la previsione (es. identificativi fittizi, codici amministrativi troppo dettagliati, descrizioni testuali lunghe).
- Alcuni errori noti del data warehouse sono stati corretti (ad esempio, valori anomali sulla variabile “abbandono”).

02

Normalizzazione delle variabili esistenti

- Sesso è stato trasformato da etichette testuali (“M”, “F”) a valori numerici binari (0 e 1).
- Tipo di corso di studi è stato semplificato in due categorie numeriche (0 = laurea triennale, 1 = laurea magistrale a ciclo unico).
- Cittadinanza è stata ridotta a una variabile binaria (0 = straniera, 1 = italiana).

03

Creazione di nuove variabili (Feature Engineering)

- Rango di prossimità: misura quanto la residenza dello studente è vicina alla sede del corso (stesso comune, province confinanti, resto della Lombardia, resto del Nord Italia, Sud e isole, estero).
- Capoluogo di residenza: 1 se lo studente vive in un capoluogo di provincia, 0 altrimenti. Ipotesi: vivere in capoluogo può riflettere un diverso contesto socio-economico.
- Scuola vs residenza: 1 se il diploma è stato conseguito nella stessa provincia di residenza, 0 altrimenti. Ipotesi: la mobilità già in fase scolastica può influenzare le scelte universitarie.

01

Trasformazione dei titoli di studio

I diplomi presentavano troppe modalità sparse. Sono stati raggruppati in categorie più compatte (es. Classico, Scientifico, Tecnico, Professionale, Estero).

Inoltre, il voto di diploma è stato arricchito con l'informazione della lode (valore massimo = 101) e poi trasformato in quartili (Q1–Q4), per distinguere le fasce di rendimento.

02

Codifica delle variabili categoriche

Molte variabili testuali (es. titolo di studio, dipartimento di iscrizione) sono state convertite in variabili numeriche attraverso tecniche di One-Hot Encoding.

Questo passaggio è fondamentale perché i modelli matematici richiedono input numerici.

03

Normalizzazione delle variabili numeriche

Le variabili continue (es. età, rango di prossimità) sono state standardizzate con lo Standard Scaler.


In questo modo, tutte hanno media 0 e deviazione standard 1, evitando che scale diverse (es. età vs codice dipartimento) pesino in modo sproporzionato nell'analisi.

Risultato del preprocessing

Infine, per evitare che i modelli imparassero solo a “prevedere la classe maggioritaria”, è stata applicata la tecnica SMOTE (Synthetic Minority Over-sampling Technique). Questa tecnica genera in modo intelligente nuovi esempi sintetici della classe minoritaria (gli abbandoni), bilanciando il dataset di addestramento. Grazie a queste operazioni, il dataset finale:

- è più compatto (variabili ridondanti eliminate);
- è più informativo (nuove feature create per catturare aspetti socio-territoriali e scolastici);
- è più coerente (tutte le variabili sono numeriche e comparabili);
- è più bilanciato (grazie a SMOTE, il modello può imparare meglio a riconoscere gli abbandoni).

Questo lavoro di preprocessing è stato determinante per permettere ai modelli di apprendere in modo efficace e produrre previsioni affidabili.



Correlation Matrix

La matrice mostra che **nessuna variabile da sola spiega l'abbandono**, ma esistono piccoli segnali utili (età più alta, non partecipare a eventi, corso a numero chiuso). Per questo motivo abbiamo bisogno di modelli predittivi che combinino più informazioni contemporaneamente, andando oltre la semplice correlazione lineare.

Confronto modelli: fase iniziale

Obiettivo

Abbiamo testato diversi algoritmi standard di machine learning, senza tuning particolare, per valutare la capacità di predire l'abbandono.

La ROC AUC indica capacità generale del modello di distinguere tra chi abbandona e chi no.

Risultati principali

- **Decision Tree:** performance modeste (ROC AUC ~ 0.56).
- **Random Forest:** leggero miglioramento (AUC ~ 0.62).
- **Logistic Regression:** recall più alto (0.64), buona capacità di intercettare gli abbandoni.
- **SVM:** equilibrio tra precision e recall, AUC ~ 0.67 . Purtroppo è lento su dataset ad alta dimensionalità!
- **XGBoost:** il migliore tra i modelli di base, con accuratezza 71% e AUC ~ 0.68 .

👉 Conclusione: i modelli più promettenti sono **Logistic Regression e XGBoost**, che sono stati scelti per l'approfondimento e il tuning.

Necessario capire il bilanciamento ottimale tra recall (intercettare il più possibile gli abbandoni) e precision (evitare troppi falsi allarmi).

Come leggere i risultati

Le confusion matrix mostrano come il modello classifica gli studenti:


- in alto a sinistra → studenti che continuano e sono correttamente previsti (True Negatives)
- in alto a destra → studenti che continuano ma il modello li segnala come a rischio (Falsi Positivi)
- in basso a sinistra → abbandoni reali non intercettati (Falsi Negativi)
- in basso a destra → abbandoni correttamente previsti (True Positives)

Le metriche principali:


- **Recall (classe 1)**: quanti abbandoni riusciamo a intercettare.
- **Precision (classe 1)**: tra i segnalati come “a rischio”, quanti lo sono davvero.
- **Accuracy**: percentuale di previsioni corrette complessive (meno utile in caso di squilibrio).
- **F1-score**: media tra recall e precision (equilibrio).
- **AUC**: capacità generale del modello di distinguere tra chi abbandona e chi no, indipendente dalla soglia.

Confusion Matrix

Logistic Regression (tuned) — Confusion matrices (Train/Test) per soglia




XGBoost (tuned) — Confusion matrices (Train/Test) per soglia




Risultati su dati di train e test e varie soglie

Logistic Regression (tuned): Train vs Test per soglia



XGBoost (tuned): Train vs Test per soglia



Risultati principali - commento

Nei modelli predittivi non otteniamo direttamente un “sì” o un “no” sull’abbandono, ma una **probabilità** (es. 0.7 = 70% di rischio).

La **soglia (threshold)** è il valore che decidiamo per trasformare quella probabilità in una decisione:

- se la probabilità è **sopra la soglia** → lo studente viene segnalato come “a rischio”;
- se è **sotto la soglia** → viene considerato “non a rischio”.

👉 Cambiando la soglia, possiamo scegliere se essere più **selettivi** (pochi segnalati ma più sicuri) o più **inclusivi** (segnalare quasi tutti i potenziali abbandoni, anche se con più falsi allarmi).

Logistic Regression (grafico 1 e 3)

- **Soglia 0.5**
 - Recall ≈ 0.64 → intercettiamo 6 abbandoni su 10.
 - Precision ≈ 0.39 → oltre metà dei segnalati non abbandona davvero.
 - Buon compromesso, ma con diversi falsi positivi.
- **Soglia ottimizzata per F1 (≈ 0.395)**
 - Recall sale a ≈ 0.81 → intercettiamo 8 abbandoni su 10.
 - Precision cala a 0.35 → aumenta il numero di falsi allarmi.
 - Accuracy scende (≈ 0.52), ma si massimizza la capacità di identificare gli studenti a rischio.
- **Soglia ottimizzata per F2 (≈ 0.215)**
 - Recall ≈ 0.98 → praticamente tutti gli abbandoni vengono catturati.
 - Precision ≈ 0.30 → moltissimi falsi positivi (3 su 10 sono reali).
 - Utile solo come scenario di “allerta massima”, non sostenibile per uso operativo.

XGBoost (grafico 2 e 4)

- **Soglia 0.5**
 - Recall ≈ 0.40 → solo 4 abbandoni su 10 vengono intercettati.
 - Precision ≈ 0.47 → migliore della LogReg: meno falsi positivi, ma più abbandoni persi.
 - AUC su test = 0.685, il migliore tra i modelli → segno che le probabilità sono ben calibrate, ma la soglia 0.5 è troppo “conservativa”.
- **Soglia ottimizzata per F1 (≈ 0.345)**
 - Recall ≈ 0.68 → intercettiamo 7 abbandoni su 10.
 - Precision ≈ 0.38 → simile alla LogReg F1, ma con un compromesso migliore (accuracy ≈ 0.60).
 - Questo è risultato il miglior trade-off.
- **Soglia ottimizzata per F2 (≈ 0.140)**
 - Recall ≈ 0.96 → quasi tutti gli abbandoni intercettati.
 - Precision ≈ 0.31 → moltissimi falsi allarmi.
 - Utile come scenario esplorativo, ma non per applicazioni dirette.

Conclusioni operative

Logistic Regression

- Più semplice e interpretabile, robusta su dati nuovi.
- Ottima per capire i fattori di rischio

XGBoost

- Modello performante, ma con rischio di overfitting.
- Usando una soglia ottimizzata per F1 (≈ 0.345) otteniamo un ottimo compromesso:
 - Recall ≈ 0.68
 - Precision ≈ 0.38
 - AUC ≈ 0.685

Confronto Train vs Test


Dai grafici delle metriche Train/Test:

- **Logistic Regression** mostra coerenza: le prestazioni su test sono vicine a quelle su train → modello stabile, poco soggetto a overfitting.
- **XGBoost** ha prestazioni molto più alte sul train (AUC ≈ 0.89) rispetto al test (AUC ≈ 0.685) → segnale di overfitting: il modello è potente ma tende a imparare troppo bene i dati di addestramento.

👉 **Raccomandazione finale:** utilizzare XGBoost (tuned) con soglia F1, che permette di intercettare 2 studenti a rischio su 3, mantenendo una precisione accettabile e la migliore capacità discriminante complessiva. La Logistic Regression resta un valido strumento complementare per l'interpretazione dei risultati e per comunicare quali variabili incidono di più.

Explainability

è l'insieme delle tecniche che ci permette di capire **quali fattori pesano di più** nella previsione di abbandono, comunicare i risultati in modo trasparente e trasformare il modello in **strumento decisionale**, che guida interventi concreti.



La regressione logistica è un modello lineare: ogni variabile ha un **coefficiente** che indica quanto influisce sulla probabilità di abbandono.

- **Coefficiente positivo** → aumenta il rischio di abbandono.
- **Coefficiente negativo** → riduce il rischio di abbandono.


Cosa vediamo dal grafico:

- Alcuni dipartimenti specifici (es. *dip_num_4*, *dip_num_11*) sono associati a un rischio maggiore.
- Studenti con titolo di studio “assente” o etichettato in certe categorie mostrano più rischio.
- Al contrario, avere un voto di diploma alto (Q4, Q3) o aver partecipato a eventi (*evento_flag*) riduce la probabilità di abbandono.

Shap Values

XGBoost è un modello molto più complesso (basato su alberi potenziati), meno interpretabile di suo.

I valori **SHAP (SHapley Additive exPlanations)** aiutano a capire quanto ogni variabile ha influito nelle singole predizioni.



Ogni punto è uno studente:

- Rosso = valore alto della variabile
Blu = valore basso.
- L'asse X mostra se quella caratteristica ha aumentato o diminuito il rischio di abbandono.

Cosa emerge dal grafico:

- **Evento_flag:** la partecipazione a eventi ha un impatto forte nel ridurre il rischio (punti rossi a sinistra).
- **Età:** valori più alti spostano la previsione verso l'abbandono (punti rossi a destra).
- **Accesso_libero** e alcuni dipartimenti: contribuiscono ad aumentare il rischio in diversi casi.
- **Voto diploma:** avere un voto alto (Q4) riduce il rischio, mentre avere voto assente o basso aumenta la probabilità di abbandono.

👉 Lo SHAP rende “visibile” come il modello complesso combina le variabili, mostrando sia l'importanza generale delle caratteristiche, sia l'effetto sui singoli studenti.



Conclusioni e sviluppi futuri

1

Early model

- I risultati ottenuti con i dati disponibili **non sono ottimali**: prevedere l'abbandono già all'immatricolazione è difficile, dato il carattere spesso aleatorio del fenomeno (molte rinunce emergono solo a settembre-ottobre).
- I modelli attuali possono comunque offrire un **warning precoce**, utile per azioni preventive.
- Per aumentare l'accuratezza, possiamo arricchire i dati in momenti chiave del percorso:

2

Modello "mid" (novembre)

- Considera solo gli immatricolati ancora attivi a inizio novembre.
- Dati aggiuntivi disponibili: calcolo tasse, piani di studio/OFA, log su piattaforme digitali (es. Kiro).

3

Modello "post-sessione"

- Dopo la prima sessione di esami, quando emergono i segnali più forti.
- Dati aggiuntivi: numero di esami sostenuti, CFU acquisiti, voti, tentativi, partecipazione a tutorati.

In questo modo possiamo costruire un **ecosistema di modelli progressivi**, che parte dall'immatricolazione ma diventa sempre più preciso man mano che si raccolgono nuove informazioni.